國 立 成 功 大 學
工業與資訊管理學系學士班
畢 業 專 題

繼往聖絕學：基於 RAG 技術的唐詩生成系統

SageAI: Chinese Ancient Poetry Generation System Based on RAG Technology

指導教授：李昇暾 教授

專題組長：莊詠晰

專題組員：陳乙慈

林顥閔

洪紹庭

中 華 民 國 一 一 三 年 十 二 月

摘要

現代社會中，唐詩經常被視為一種難以理解的語言，彷彿與當代生活脫節。許多人認為唐詩相當八股，甚至認為唐詩僅僅為封建社會所遺留之產物。然而，唐詩內蘊含優美文字意境、深遠的文化底蘊、古往先賢思想以及先賢面對生活各種劇變及壓力之心境轉換和經驗分享。面對現今凡事講求創新和拋棄舊有思想的社會，其逐漸面臨式微和失傳的危機。因此，此次研究的目標為結合古典文學與現代生成式 AI 技術，針對使用者的心情以及敘述，生成相對應的唐詩，致力於以唐詩之美，打造撫慰使用者心靈的 AI 智慧導師系統。

此次研究透過最新的檢索增強生成（Retrieval-Augmented Generation, RAG）技術，力求於使大型語言模型可以更精確地遵循相關文本內容以生成回覆。此系統的架構以 ChromaDB 作為向量資料庫，資料來源為 GitHub 上的開源語料庫 Chinese-poetry 其內的全唐詩和宋詩共計 230,310 首詩詞，且以 Gemini Pro 作為 RAG 使用所需的 LLM，再者為了進行嵌入模型的微調，本研究選擇 GitHub 上 NiuTrans/Classical-Modern 的雙語資料庫作為微調資料，採用 Sentence Transformers 庫中的預訓練模型 nomic-embed-text-v1.5 作為基礎模型，透過微調模型以增強 Retriever 的效果。此外，本研究亦嘗試於系統增加情感分析、HyDE (Hypothetical Document Embeddings)、Cross-Encoder 以及 Finetuned LLM 等進階 RAG 技術，使研究生成的詩詞更加接近唐詩的風格。

在實驗部分，本研究利用消融實驗(Ablation Study)得出，HyDE 以及 Finetuned LLM 對於模型表現具有顯著影響，能夠有效提升模型表現。進一步根據此二因子的全因子實驗發現，無論是僅使用 HyDE、僅使用 Finetuned LLM 或是同時使用此兩種方法，在唐詩生成上皆有良好的表現。

關鍵字：生成式 AI、檢索增強生成、大型語言模型、情感分析、HyDE、消融實驗

目錄

第一章 緒論 8

第一節 研究動機 8

第二節 研究目標 9

第三節 研究架構與流程 9

第二章 文獻回顧 12

第一節 檢索增強生成 12

第二節 Sentence Transformers 13

第三節 Advanced RAG 13

第四節 Model Evaluation 16

第三章 模型建構 18

第一節 基礎 RAG 建構 18

第二節 進階 RAG 建構 23

第四章 研究結果 27

第一節 效能評估方法概述 27

第二節 各 Feature 組合之實驗結果 29

第三節 國文領域專家問卷分析 47

第四節 小結 50

第五章 結論與未來展望 51

第一節 結論 51

第二節 研究貢獻 52

第三節 未來展望 52

第四節 系統演示 53

第六章 參考文獻 56

圖目錄

圖 1-1 研究流程圖.....11

圖 2-1 HyDE 流程圖.....14

圖 3-1 基礎 RAG 模型架構圖.....18

圖 3-2 NiuTrans/Classical-Modern 的雙語資料庫資料格式範例.....18

圖 3-3 Chinese-poetry 中的全唐詩資料格式範例.....19

圖 3-4 進階 RAG 模型架構圖.....23

圖 3-5 訓練資料之輸入與輸出示範.....26

圖 4-1 評測指標關聯圖.....28

圖 4-2 填答人員背景分布.....48

圖 5-1 系統最終架構圖.....51

圖 5-2 系統使用者介面.....53

表目錄

表 3-1 訓練相關參數.....20

表 3-2 評估與保存策略.....20

表 4-1 實驗時所使用的 Prompt.....29

表 4-2 基礎 RAG 和不使用 RAG 的比較實驗組合.....30

表 4-3 各組合之 Answer Relevance 指標實驗結果.....30

表 4-4 Answer Relevance 指標之 ANOVA 檢定.....31

表 4-5 各組合之 Execution Time 指標實驗結果.....31

表 4-6 Execution Time 指標之 ANOVA 檢定.....32

表 4-7 Ablation Study 實驗組合.....32

表 4-8 各組合之 Answer Relevance 指標實驗結果.....33

表 4-9 Answer Relevance 指標之 ANOVA 檢定.....34

表 4-10 Answer Relevance 指標之 Post Hoc Comparisons.....34

表 4-11 各組合之 Groundedness 指標實驗結果.....35

表 4-12 Groundedness 指標之 ANOVA 檢定.....36

表 4-13 Groundedness 指標之 Post Hoc Comparisons.....36

表 4-14 各組合之 Context Relevance 指標實驗結果.....37

表 4-15 Context Relevance 指標之 ANOVA 檢定.....38

表 4-16 Context Relevance 指標之 Post Hoc Comparisons.....38

表 4-17 各組合之 Execution Time 指標實驗結果.....39

表 4-18 Execution Time 指標之 ANOVA 檢定.....40

表 4-19 Execution Time 指標之 Post Hoc Comparisons.....40

表 4-20 全因子實驗組合.....41

表 4-21 各組合之 Answer Relevance 指標實驗結果.....42

表 4-22 Answer Relevance 指標之 ANOVA 檢定.....42

表 4-23 各組合之 Groundedness 指標實驗結果.....43

表 4-24 Groundedness 指標之 ANOVA 檢定.....44

表 4-25 Groundedness 指標之 Post Hoc Comparisons.....44

表 4-26 各組合之 Context Relevance 指標實驗結果.....45

表 4-27 Context Relevance 指標之 ANOVA 檢定.....45

表 4-28 各組合之 Execution time 指標實驗結果.....46

表 4-29 Execution time 指標之 ANOVA 檢定.....46

表 4-30 Execution time 指標之 Post Hoc Comparisons.....47

表 4-31 實際唐詩與大型語言模型生成詩句之平均值比較.....48

表 4-32 實際唐詩與大型語言模型生成詩句之 T 檢定.....48

表 4-33 self-design RAG 與 Gemini Pro 之平均值比較.....49

表 4-34 self-design RAG 與 Gemini Pro 之 T 檢定.....49

表 4-35 self-design RAG 與 Gpt4o 之平均值比較.....49

表 4-36 self-design RAG 與 Gpt4o 之 T 檢定.....49

第一章 緒論

第一節 研究動機

在當代社會，唐詩常被視作晦澀難懂的語言，似乎與現代生活格格不入。許多人將唐詩看作一種僵化的形式，甚至視為封建時代的殘留物。在現今社會極力強調創新與拋棄傳統的氛圍下，唐詩因此逐漸式微，正被推向遺忘的邊緣。然而，唐詩中蘊含的文學之美、文化深度以及古人的思想智慧和在生活變遷中的心境轉折，依然具有不可忽視的價值。

因此，本研究期望建立一個 AI 智慧導師系統，其不僅是知識的收藏者，更是智慧的傳播者。該系統旨在利用人工智慧技術，特別是生成模型，將古人的思想轉化為當代人的精神食糧，幫助使用者在現代生活的壓力中找到情感的共鳴與心靈的慰藉。然而，現今的主流 AI 生成模型，如 Gemini Pro 和 OpenAI，雖然在現代文本生成上具有較強的能力，但在生成符合唐詩格律要求的絕句和律詩上存在明顯的局限性。這些模型往往無法準確把握五言、七言詩的字數句數和押韻規則，導致生成的作品缺乏古典韻味與文學水準。

為了突破這一技術瓶頸，研究結合韻律分析、語言模型提升等技術，實現符合唐詩形式要求的生成效果。系統不僅能夠分析並調整詩詞的格律結構，還可以透過情感分析和主題連結技術，生成富有情感深度和文化價值的詩作，並適應多樣化的應用場景。

我們的系統將提供使用者參與創作的機會，從而在實現詩歌生成的同時，促進文化知識的傳播和情感交流。此系統的發展不僅有助於弘揚傳統文化，更能使唐詩在現代社會中煥發新生，為當代人提供一個重新認識、欣賞和應用唐詩的橋梁。

第二節 研究目標

本研究旨在結合古典文學與現代生成式 AI 技術，透過檢索增強生成（Retrieval-Augmented Generation, RAG）技術，建立一個能夠根據使用者的心情與描述生成相應唐詩的回覆系統。此系統能夠基於使用者輸入的語境與情感需求，準確地從古典唐詩庫中檢索出相關內容，並在此基礎上生成符合使用者當下心境的詩詞回應，以致力於藉由唐詩的優美意境與深刻內涵，為使用者帶來情感上的共鳴與心靈的撫慰。

第三節 研究架構與流程

(一)、 定義研究方向：本研究以近期最新的 RAG 技術為參考，結合自身對古典文學的興趣，進一步明確研究方向。

(二)、 文獻探討與回顧：透過閱讀文獻以了解相關技術核心，並參考文獻中的研究方法，以此為基礎，建構出 RAG 整體架構。

(三)、 資料蒐集：收集網路上文言文與譯文的對應資料，並進行資料清洗與整理，以利於後續的資料庫建構以及模型微調。

(四)、 嵌入模型微調：為了提升檢索與生成的準確性與相關性，透過微調嵌入模型(Embedding Model) 以根據任務需求進一步提升語義表徵，使模型更好地理解上下文以及文言文與白話文之間的對應關係，從而提升檢索結果的品質。

(五)、 模型評估：針對微調好的嵌入模型進行命中率(Hit rate)和平均倒數排名(Mean Reciprocal Rank score, MRR score) 指標的計算。

(六)、 模型表現：根據 Embedding model 模型在 MRR 以及 Hit rate 指標上的表現，決定是否調整參數重新微調。

(七)、 資料庫建構：運用 ChromaDB 結合自行訓練的 Embedding model，將整理

過後的資料及其轉換為向量後的表示，存入資料庫中。

(八)、 RAG 框架建購：結合大型語言模型、資料庫以及自行訓練的 Embedding Model 串接出 RAG 架構。

(九)、 進階 RAG 建構：基於基礎 RAG 架構，加入 Hypothetical Document Embeddings (HyDE)、情感分析、Cross-Encoder、微調大型語言模型方式，以增加 RAG 的表現。

(十)、 整體架構評測：運用 Ablation Study 的觀念，針對各種進階 RAG 方法的組合進行模型評測，以找出對模型有顯著影響的因子，再結合全因子實驗，找出最好的進階 RAG 組合。

(十一)、 輸出最佳功能組：根據 Ablation Study 和全因子實驗的評測結果，找出最好的模型組合。

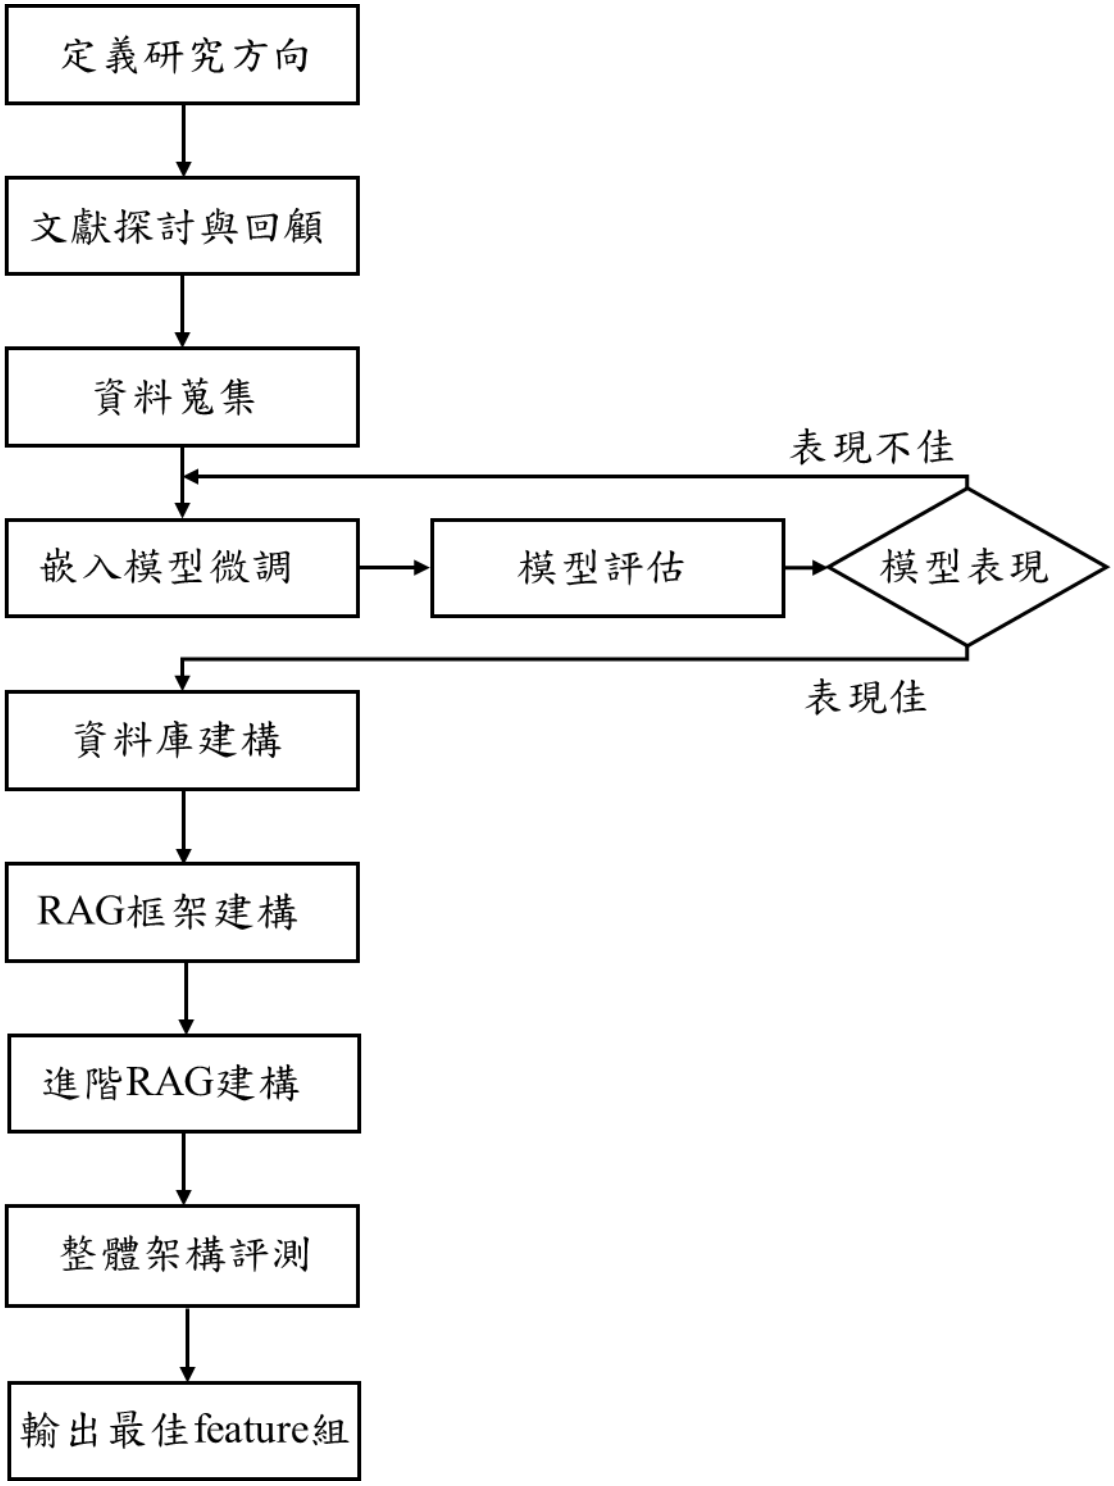
定義研究方向
文獻探討與回顧
資料蒐集
表現不佳
嵌入模型微調
模型評估
模型表現
表現佳
資料庫建構
RAG框架建構
進階RAG建構
整體架構評測
輸出最佳feature組

圖 1-1 研究流程圖

第二章 文獻回顧

本章節分為四個小節，分別探討研究中會使用到的相關知識和概念。2.1 節將介紹研究中的核心技術 Retrieval-Augmented Generation (RAG)，2.2 節介紹訓練模型時會用到的 Sentence Transformers，2.3 節介紹用於提升 RAG 效果的 Advanced RAG，最後 2.4 節則介紹模型評測的相關方法。

第一節 檢索增強生成

檢索增強生成 (RAG) 的方法是由 Lewis 等人於 2021 年提出的一種結合參數記憶與非參數記憶的混合架構，旨在解決大型語言模型在處理知識密集型任務時的不足之處。傳統大型語言模型儘管在自然語言處理中表現出色，卻因其回應主要基於過去的訓練資料，可能導致偏見、幻覺或不準確的情況。

RAG 模型的核心是透過檢索相關的外部知識來增強生成過程，使模型具備靈活應對特定領域知識需求的能力。具體來說，RAG 模型由兩個主要組件構成：檢索器與生成器。檢索器使用密集向量索引來從大型知識庫中檢索相關內容，並將檢索到的文件作為上下文供生成器使用，從而提高生成的準確性和相關性。

相比傳統的僅依賴參數記憶的語言模型，RAG 模型在開放域問答及知識密集型生成任務上表現出色。模型能在不重新訓練的情況下，靈活地擴展至特定領域或組織內部知識庫，克服大型語言模型在處理專業或知識密集型任務時的侷限性，進一步提升其在自然語言生成任務中的準確性和多樣性。

第二節 Sentence Transformers

本研究中，我們採用了 Reimers 和 Gurevych 於 2019 年提出的 Sentence-BERT (SBERT) 作為句子嵌入的方法。SBERT 是對原始 BERT 模型進行修改，使用了 Siamese 和 Triplet 神經網絡架構來生成語義上更具意義的句子嵌入。與傳統 BERT 模型需要同時輸入兩個句子進行比較不同，SBERT 透過將句子轉換為固定大小的向量，使句子相似性比較可以通過簡單的餘弦相似度高效計算，極大地降低了計算成本和時間。

SBERT 透過微調 BERT，專門用於生成語義豐富的句子嵌入，並能在語義相似性比較、資訊檢索等任務中顯著提升效能。文獻中亦指出，其在多個標準語義文本相似性任務中表現優異，超越了許多當前的句子嵌入方法，包括 InferSent 和 Universal Sentence Encoder。

在本研究的 RAG 框架中，SBERT 作為嵌入模型的一部分，能夠增強語意檢索與上下文匹配的準確性，通過生成高效的語義嵌入，進一步提升系統在檢索增強生成過程中的表現，從而滿足古文應用需求並支持更精確的語義分析。這種嵌入技術的應用，使得模型能在大規模文本檢索與生成任務中保持高效與精準，提升了對語義複雜度的處理能力。

第三節 Advanced RAG

針對進階 RAG 的部分，本研究使用了 Hypothetical Document Embeddings、Cross-Encoder、情感分析及微調大型語言模型共四種方式，以提升 RAG 的整體效能。下文將會分別介紹這四種方式的詳細內容。

壹、 Hypothetical Document Embeddings (HyDE)

研究根據 Luyu Gao 與 Xueguang Ma 與 Jimmy Lin 與 Jamie Callan 於 2022 年提出的 Hypothetical Document Embeddings 方法，其能解決無標記相關性資料情境下的密集檢索問題。HyDE 模型通過生成一個假設性文件來捕捉查詢的相關性，目的是提供一個與查詢相關的假設性示例。生成的文件雖可能存在著不準確的細節，但能夠反映出查詢的核心相關性，這使模型在進行檢索時，能有更好的表現。且論文中的實驗也表明，HyDE 在多種任務和語言（如網頁搜索、問答、事實驗證等）中顯著提升了檢索性能。

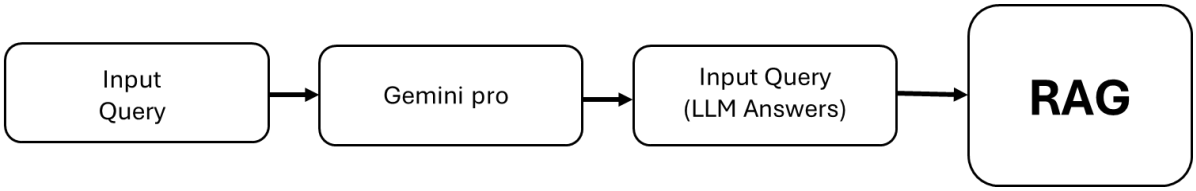

圖 2-1 HyDE 流程圖

貳、 Cross-Encoder

在文獻回顧中，Cross-Encoder 作為強大的語義匹配工具，在需要精細語義比較和上下文關聯任務中，展現出色的表現。Nogueira 和 Cho 於 2020 年提出的基於 BERT 的 Passage Re-ranking 方法就是 Cross-Encoder 的一個典型應用，它通過聯合編碼兩段文本來進行語義匹配，顯著提升了檢索結果的精確度和排序效果。相比於僅依賴向量相似度計算的雙塔架構（Bi-Encoder），Cross-Encoder 通常能提供更精確的結果。

在 Pickett 等人（2024）的研究中，他們提出了 Dartboard Crosscoder（D-CC）和 Dartboard Hybrid（D-H）兩種基於 Cross-Encoder 的變體，這些變體透過利用 Cross-Encoder 的強大語義匹配能力來對初始檢索結果進行重新排序，從而提升了 RAG 系統的整體效能。具體來說，這些變體透過最大化與查詢相關的資訊增益來

提升檢索策略，既提升了檢索的精確性，也有效降低了檢索結果中的冗餘度。相比之下，傳統的檢索方法如 KNN 或基於最大邊際相關性（Maximal Marginal Relevance, MMR）的方法雖然也考慮了檢索結果的多樣性，但在應用於需要精確語義匹配的任務時，往往難以與 Cross-Encoder 的表現相比。

基於這些研究，本研究嘗試將 Cross-Encoder 融入 RAG 架構，以期望在檢索精準度和語義相關性方面取得更好的表現，從而提升系統在檢索和生成過程中的整體效能。這種方法能充分利用 Cross-Encoder 對語義細節的捕捉能力，並在生成過程中提供更準確的上下文相關回應。

參、 情感分析

情感分析是自然語言處理中一個重要的領域。Zhao 和 Welsch 等人於 2024 年針對金融情感分析提出了一個整合檢索增強生成 (RAG) 與大型語言模型 (LLMs) 的框架，利用指令調整與市場反饋，動態地調整知識來源的權重。該方法以提升模型對情緒的準確性為目標，通過外部知識源豐富 LLM 在生成過程中的輸出，使其在應用於市場預測與投資策略制定中顯著提高了效能。

基於上述文獻，本研究思考於其他領域上的情感分析與 RAG 框架的結合應用，如詩詞分析和生成，利用情緒分數指導文本生成過程。透過分析詩詞的情感屬性，模型可以產生更符合情緒需求的文本，增強生成的準確性與情感一致性。這種應用提供了更多精確的語義與情緒的洞見。

肆、 微調大型語言模型

隨著大型語言模型（LLM）的應用範疇逐漸擴大，監督式學習方法被廣泛應用於模型微調 （Finetuning），以針對特定任務提高模型的準確性和專業性。例如，Devlin 等人 2019 年提出的 BERT 模型通過監督式學習微調來適應多種自然語言

處理任務，包括問答和情感分析，顯示了監督式學習在特定目標任務上調整模型生成的有效性。BERT 模型的微調過程展示了利用標記資料來引導模型生成，使其具備在不同任務中生成準確且符合語境需求的能力。

Yang 等人於 2019 年提出的 XLNet 模型在微調過程中使用了監督式學習方法，證明此方法在生成式和理解式任務中的適應性。XLNet 結合了監督資料來微調生成內容的準確性，並在生成結果的上下文關聯性和一致性上達到了更高水準。這些研究表明，監督式微調方法能夠針對特定任務進行模型提升，提升生成結果的品質。

此外，OpenAI 在發布 GPT-2 時展示了如何通過微調來改進模型在特定任務上的性能，通過監督式學習微調以適應具體生成任務。雖然 GPT-2 的初始訓練是無監督的，然而透過監督式微調，模型能夠生成更貼近任務需求的文本內容，並提升生成結果在風格和主題上的一致性。

綜合上述文獻，本研究嘗試利用監督式微調方法以提升模型的專精能力，並試圖在唐詩生成任務上顯示出顯著優勢。

第四節 Model Evaluation

研究中的 RAG 架構模型是由多個部分所組成，且分別影響著模型的整體性能，因此，在深度學習的研究中，消融實驗（Ablation Study）是一種常見的方法，用於分析模型不同組件對最終性能的影響。例如 Nicolas Carion 等人於 2020 年提出了一個基於 Transformer 架構的目標檢測模型，為了驗證模型架構的有效性，透過一系列的消融實驗，詳細探討了各個組件對模型性能的貢獻。本研究亦採用消融實驗來評估 Advanced RAG 系統中不同特性的貢獻。指標部分，則根據 Shahul Es 等

人於 2023 年提出的 RAGAS 框架，運用 RAGAS 中的回答相關性(Answer Relevancy)、上下文相關性(Context Relevancy)、真實性(Groundedness) 三指標，對檢索增強生成系統進行無需參考答案的自動化評估。

第三章 模型建構

第一節 基礎 RAG 建構

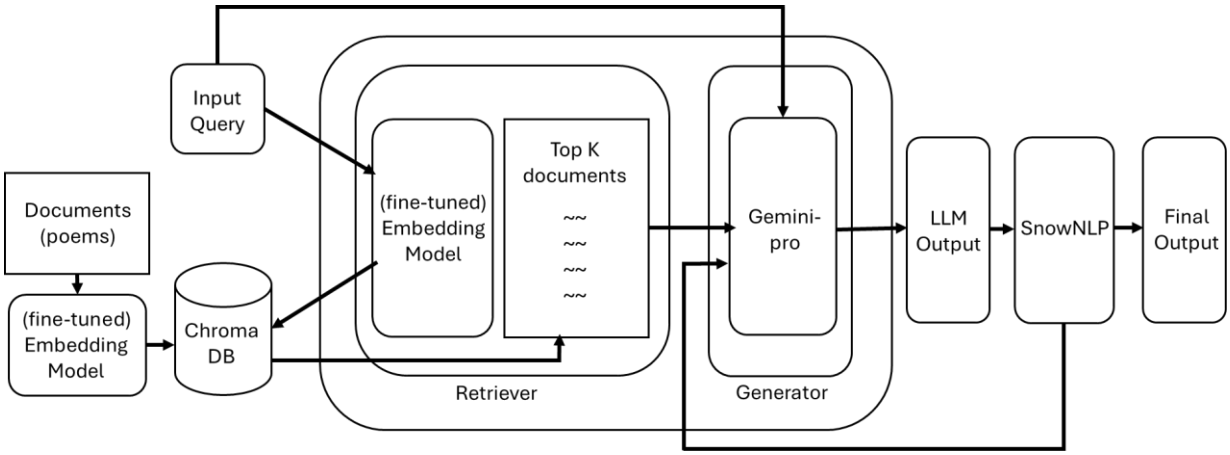

圖 3-1 基礎 RAG 模型架構圖

壹、 資料蒐集與預處理

本研究蒐集 GitHub 上 NiuTrans/Classical-Modern 的雙語資料庫資料，以及 GitHub 上 Chinese-poetry 中的全唐詩資料。對於這兩組資料，我們首先進行重複資料和不完整資料的過濾，並使用 OpenCC 套件將簡體字資料轉換為繁體字。NiuTrans/Classical-Modern 資料庫涵蓋各朝代的文言文及其對應的現代譯文語料，經整理後，我們將資料以一句古文對應一句現代譯文的形式進行排列，以用於模型的微調訓練。另一方面，Chinese-poetry 資料集包含約 23 萬首唐詩與宋詩，經過清洗與整理後，預計作為資料庫中的基礎資料使用。

古文：假之以便，唆之使前，断其援应，陷之死地。
现代文：故意露出一些破绽，以引诱敌人深入我方，乘机切断他的后援和前应，最终陷他于死地。

古文：遇毒，位不当也。
现代文：这就如《易经》 噬嗑 卦中说的，咬坚硬的腊肉而伤了牙齿一样，敌人为贪求不应得的利益，必招致后患。

圖 3-2 NiuTrans/Classical-Modern 的雙語資料庫資料格式範例

```
{
    "author": "宋太宗",
    "paragraphs": [
        "常思清淨世情閑，遥認天平我扣關。",
        "莫道玄談些子是，鳳飛鶴宿九疑山。"
    ],
    "title": "緣識　其二九",
    "id": "190e888e-b9d5-4def-9133-8bc8a653dbcd"
},
```


圖 3-3 Chinese-poetry 中的全唐詩資料格式範例

貳、 微調嵌入模型(Finetune Embedding Model)

為了進行嵌入模型的微調，本研究選擇 GitHub 上 NiuTrans/Classical-Modern 的雙語資料庫作為微調資料來源。該資料庫包含成對的文言文和現代譯文對應資料，適合用於模型的微調，能夠強化語言模型對文言文和現代語言之間語義轉換的能力。接著，本研究採用了 Sentence Transformers 庫中的預訓練模型 nomic-embed-text-v1.5 作為基礎模型。此模型的選擇基於 Nussbaum 等人於 2024 年對 Nomic 模型的介紹。該論文指出，Nomic 模型在處理長文本嵌入時表現出色，並在多項語義處理任務中超越了其他模型，展現出優異的性能和強大的泛化能力。

在微調過程中，我們將近 5 萬首的資料隨機劃分為 9:1 的訓練集和驗證集，以確保模型的泛化能力和穩健性。為了進一步強化模型的嵌入效果，我們採用 Multiple Negatives Ranking Loss 作為損失函數。該損失函數適用於嵌入模型的訓練過程，能夠有效地增強嵌入向量之間的語義差異，使得模型能夠更準確地區分和捕捉語義上的細微變化。這種配置不僅提升模型對語義的捕捉能力，還有助於更好地支持中文古文與現代語言之間的語義對應，從而實現更高效、更準確的語義匹配和檢索。

表 3-1 訓練相關參數

訓練回合數 (num_train_epochs)	1
單個裝置上的訓練批次大小(per_device_train_batch_size)	1
單個裝置上的評估批次大小 (per_device_eval_batch_size)	16
預熱比例 (warmup_ratio)	16
混合精度訓練 (FP16) (fp16)	TRUE
16 位元浮點數 (BF16) (bf16)	FALSE
批次採樣方式 (batch_sampler)	BatchSamplers. NO_DUPLICATES

表 3-2 評估與保存策略

評估策略 (eval_strategy)	steps
評估間隔步數 (eval_steps)	5000
模型保存策略 (save_strategy)	steps
保存間隔步數 (save_steps)	5000
最大保存數量 (save_total_limit)	2
記錄間隔步數 (logging_steps)	100
最高效能模型加載 (load_best_model_at_end)	TRUE

在模型微調完成後，我們利用測試資料對模型進行了性能評估。具體而言，將測試資料中的白話文文本輸入嵌入模型，檢測其是否能準確地檢索出對應的文言文。評估指標包括平均 Hit Rate (命中率) 和 Mean Reciprocal Rank (MRR, 平均倒數排名) 兩項。

平均 Hit Rate (命中率)：設定 top_k 等於 5，從模型檢索出的最相似 5 筆文

件中，檢查是否包含正確的文言文對應文本。若檢索結果中包含正確文件，則該次測試得 1 分，否則得 0 分。模型的測試結果顯示，平均命中率達到 0.8088，表明模型在檢索任務中的準確度較高，能夠有效匹配到相關內容。

Mean Reciprocal Rank (MRR, 平均倒數排名)：該指標用於衡量檢索結果的排序品質。在檢索出的 5 筆文件中，查看正確的文件在排序中的位置。若正確文件排在第一位，則得 1 分；若排在第三位，則得 1/3 分 (以倒數表示)；未匹配到正確文件則得 0 分。模型測試結果顯示，平均 MRR 為 0.740403，表明模型能夠在大多數情況下將正確文件排在較高的排名位置，有助於提高檢索精準度。

參、 資料庫建構

利用微調好的嵌入模型，本研究將整理自 Chinese-poetry 資料集中的全唐詩和宋詩共計 230,310 首詩詞轉換為嵌入向量。這些向量的生成能夠在後續的檢索過程中，量化不同詩詞之間的語義相似性，使模型能夠更精確地辨別和比較詩詞的語意關聯。這種嵌入方式能捕捉詩詞內容的深層語義特徵，為後續語義檢索和分析提供基礎。

接著，研究將原文詩詞與其對應的嵌入向量一併存入 ChromaDB 中。ChromaDB 是一個專門處理大規模向量資料的資料庫，具備高效的檢索與存儲能力。其設計特點使其能夠針對高維向量進行快速檢索，尤其適合用於語義相似性檢索和文本匹配任務。透過將嵌入向量與 ChromaDB 結合，我們的系統能夠更快速地檢索出與給定詩詞具有相似語義的內容，從而提升檢索效率與準確性，滿足大規模古典詩詞資料庫應用的需求。這種設計為後續在語言處理、詩詞生成及語義分析等領域的應用提供有效支持。

肆、 格律驗證

在 RAG 架構中，當大型語言模型生成唐詩後，研究將利用 SnowNLP 套件對生成的詩句進行斷句處理，並通過將漢字轉換為拼音的方式，對詩句的字數、句數和押韻進行系統性分析與驗證。若在格律方面出現錯誤，研究將根據檢測到的問題部分進行重新生成，以確保詩句符合格律規範。格律驗證過程中，我們採用 SnowNLP 的漢字轉羅馬拼音功能進行檢查。例如，生成的詩句為「秋月團圓夜，我心寄故鄉。佳節倍思親，明月照空房。」我們會檢查偶數句的最後一個字的拼音。在此詩句中，檢查「鄉」與「房」這兩個字的拼音。「鄉」的拼音為 xiang，而「房」的拼音為 fang，兩者拼音的結尾皆為 g，因此符合押韻規則。

透過此方法，我們確保生成的詩句在字數、句數和押韻規則上的準確性，使生成的唐詩更加符合傳統詩詞的格律要求，也有助於提升系統在詩詞生成上的品質。

伍、 架構串接

本研究將微調後的嵌入模型、ChromaDB 和大型語言模型進行整合，以實作檢索增強生成 (RAG) 架構。在大型語言模型的選擇上，研究選用了由 Google 開發的 Gemini Pro，該模型能夠免費通過 API 進行串接使用，並在多種任務中展現出卓越的表現。整體架構的運作流程如下：當使用者輸入文本後，模型首先利用嵌入模型將輸入轉換為向量表示。接著，該向量將被送入 ChromaDB 進行檢索，以找到與輸入最相似的五個文本參考。隨後，Gemini Pro 將根據使用者的輸入及從 ChromaDB 檢索回來的五個參考文件生成相應的回覆。為了進一步提升生成內容的品質，研究還對生成結果進行格律驗證，確保生成的內容在語法、韻律及內容一致性方面達到較高水準。此架構設計使 RAG 系統能夠在檢索和語意生成中保持高度的準確性與相關性，提供用戶更精確和合適的生成結果。

第二節 進階 RAG 建構

進階 RAG 的目的是在基礎 RAG 架構之上，透過額外的技術與方法進一步增強其效能與表現。本小節中，我們將逐一介紹研究中所採用的進階 RAG 技術，並詳述其如何提升系統的檢索與生成能力。

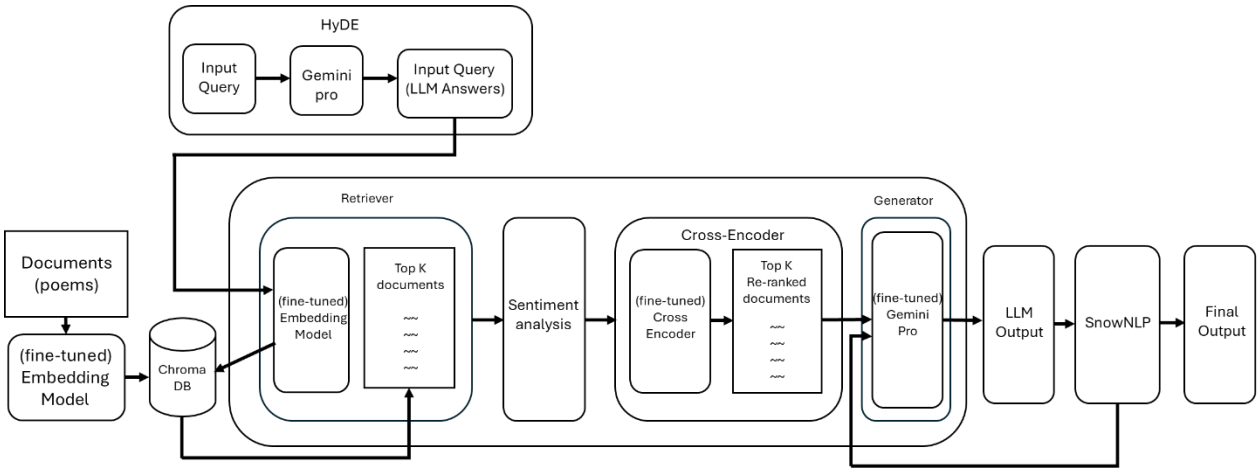

圖 3-4 進階 RAG 模型架構圖

壹、 Hypothetical Document Embeddings (HyDE)

在 RAG 實作中，常會遇到使用者輸入與資料庫中現有文件內容存在較大差距的情況，這可能導致無法有效檢索到與使用者輸入相關的內容描述。為了解決這一問題，本研究引入 Hypothetical Document Embeddings（HyDE）的概念。先利用大型語言模型根據使用者輸入生成一個假設性的結果，作為潛在的參考內容。接著，將該假設性結果輸入資料庫進行檢索，以查找最相似的文件。儘管最初生成的假設性結果可能存在細節上的不準確性，但這種方法能夠有效地增強資料庫檢索的表現，幫助模型更準確地找到與使用者輸入相關的文件。

透過 HyDE 的方法，能夠有效提升系統在面對模糊或不常見查詢時的靈

活性，使模型能夠適應更廣泛的應用場景。即便在資料庫中缺乏直接匹配的情況下，也能透過假設性結果的引導，提高檢索到相關內容的概率，從而提升系統整體效能。

貳、 情感分析

在情感分析中，我們選擇使用 SnowNLP 作為情感分析工具。SnowNLP 是少數能夠針對中文文本進行情感分析的自然語言模型，其情感分析功能基於單純貝氏分類器 (Naive Bayes Classifier)。根據 Vivek Narayanan、Ishan Arora 和 Arjun Bhatia 於 2013 年的研究，單純貝氏分類器在情感分類任務中表現出顯著的效能，能夠準確地將文本情緒歸類。使用 SnowNLP 進行分析時，使用者只需輸入任何中文語句，即可獲得一個範圍從 -1 到 +1 的情感分數，數值越高表示情緒越正向。

本研究將利用 SnowNLP 對使用者輸入和 RAG 架構中從向量資料庫中檢索回的相關文件進行情感分析，並比較兩者的情感分數。若檢索回的文件與使用者輸入的情感分數相差超過 0.1，該參考文件將被視為不適當並予以剔除，以避免對後續的生成過程造成影響或引入「噪音」。此過濾機制有助於提高模型的生成品質，確保參考文件與使用者輸入在情感層面上的一致性，從而增強生成內容的相關性與準確性。

參、 Cross-Encoder

不同於嵌入模型 (Embedding Model) 將文字輸入轉換為高維度向量，Cross-Encoder 的輸入為兩段文本，其輸出則是一個介於 0 到 1 之間的相關性分數。本研究利用 Cross-Encoder 將使用者的輸入查詢 (query) 與檢索器 (retriever) 檢索出的每一筆文本進行相關性分數計算，並根據計算結果重新排序檢索結果，以提升 RAG 系統的整體表現和精準度。

在模型微調方面，本研究選擇 Sentence Transformers 庫中的預訓練模型

cross-encoder/ms-marco-MiniLM-L-6-v2 作為基礎模型，並採用 NiuTrans/Classical-Modern 雙語資料庫進行微調。微調過程中，研究將雙語資料庫中的文言文和現代譯文進行配對並打亂順序，對於這些錯誤配對的資料設定標籤為 0，而正確配對的資料則設定標籤為 1。通過這樣的標記和微調過程，使模型更能夠準確地識別文本間的語義相關性，並提高其在語義匹配上的能力。

在 RAG 架構的應用中，微調後的 Cross-Encoder 首先透過 Retriever 檢索出 10 筆相關文件，隨後利用 Cross-Encoder 計算每一筆文件與使用者輸入之間的相關性分數。系統會排除相關性分數為負值的文件，並從中選取前五筆相關性最強的文件作為後續大型語言模型生成回應的參考輸入。此過程不僅增強檢索結果的準確性，還提升生成內容的相關性與品質，使系統能夠更好地滿足使用者的需求。

肆、 大型語言模型的微調

在本研究中，將資料分為輸入 (input) 和輸出 (output) 兩部分。以圖 3-5 為例，輸入格式包括標題 (title)、作者 (author)、以及資料庫中對應於《唐詩三百首》的標籤 (tag)。輸出部分則為具體的唐詩文本內容。整體上，構建了共計 367 筆的訓練資料集，並以此資料集對 Gemini 1.5 Flash 進行監督式訓練。

訓練過程中，模型的總訓練時間為 21 分 52 秒，批次大小 (Batch size) 設為 4，學習率 (Learning rate) 為 0.001。這樣的設定旨在確保模型能夠有效學習輸入與輸出的對應關係，從而提升其在生成唐詩文本時的準確性和表現。通過結合標題、作者和標籤等多重資訊，模型可以更全面地理解和生成符合格律和文體風格的唐詩文本，進一步提升其在語意生成和文本創作任務中的應用能力。

input	output
Title: 在嶽詠蟬 Author: 駱賓王 Tags: 唐詩三百首, 詠物, 詠物詩, 五言律詩	西陸蟬聲唱，南冠客思侵。 那堪玄鬢影，來對白頭吟。 露重飛難進，風多響易沈。 無人信高潔，誰爲表予心。

圖 3-5 訓練資料之輸入與輸出示範

第四章 研究結果

本章節首先透過實驗證明，在唐詩生成任務上，使用 RAG 的有效性。接著針對研究中利用 Advanced RAG 讓大型語言模型（LLM）根據輸入內容生成詩的實驗結果進行說明。我們設計四種特性分別是情感分析模塊、HyDE 模塊、Cross-Encoder 模塊及 Finetuned LLM 模塊，使用 Ablation study 方法逐一移除這些特性來觀察系統性能在測試指標上的變化，此過程有助於深入理解每個特性在系統中的作用及其對最終結果的貢獻。最後，我們運用全因子實驗 (Full Factorial Design) 設計，針對對模型有顯著影響的因子，測試其所有可能的組合，以全面評估這些因子對整體系統的影響及其交互作用。

第一節 效能評估方法概述

為了能夠完整對生成詩的表現進行評估，我們採用了兩種評斷方式。首先採用了客觀量化方法為 Cosine Similarity 餘弦相似度來評分，另外為了了解「人」對於詩的感受及文字的主觀想法，我們也採用問卷方式深入和專家探討生成詩的表現。

壹、 Cosine Similarity

一、 回答相關性(Answer Relevance)

該指標用於評估生成的回答是否直接針對給定的問題進行回應。Answer Relevance 不考慮答案的事實正確性，而是重點評估答案的完整性，側重於確保生成的回答能夠對用戶的問題提供具體和有針對性的回應以及是否避免了多餘訊息的出現。

二、 真實性(Groundedness)

該指標評估生成的回答是否與檢索到的上下文內容一致，從而避免模型生成無根據的內容或出現不準確的陳述。Groundedness 的評估有助於確保模型生成的回答建立在可信賴的資訊基礎上，並減少生成過程中的幻覺和誤導性資訊。

三、 上下文相關性(Context Relevance)

此指標用於評估檢索到的上下文內容是否足夠集中並且與問題有足夠的相關性。Context Relevance 確保所檢索的文件在語意上能夠有效支持問題，避免與主題無關或分散的內容干擾，從而提高回答的準確性和一致性。

上述三指標的相關性，皆使用餘弦相似度（Cosine Similarity）進行計算，公式如下：

$$S(Q,A) = \frac{Embedding(Q) \cdot Embedding(A)}{\|Embedding(Q)\| \|Embedding(A)\|} \tag{1}$$

當 S(Q,A) 越接近 1，代表 Q 和 A 的相關性越高。

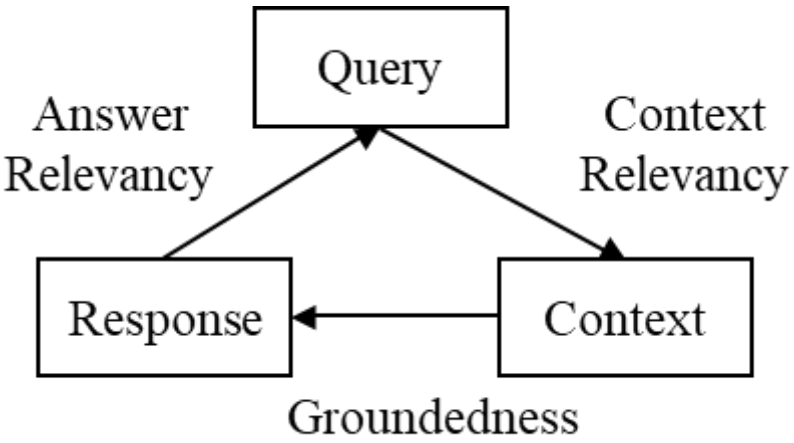

圖 4-1 評測指標關聯圖

貳、 專家問卷評分

本研究邀請成功大學國文領域的相關教授、學生以及國高中國文老師共 17 人，對生成的詩作進行問卷評分。問卷內容涵蓋兩個主題：中秋節以及回歸故里。詩作來源包括本研究中使用 RAG 模型生成的作品、現有經典詩作，以及由 GPT-4o 和 Gemini Pro 生成的作品。評分標準則包含以下六項：情感表達、意境營造、語言流暢度、格律與韻律、主題相關性，以及創意表現。

第二節 各 Feature 組合之實驗結果

表 4-1 實驗時所使用的 Prompt

Question
今天去爬了陽明山，那邊的風景很壯麗，令人難以忘記。請以此主題創作一首五言律詩。
昨天我同學出車禍過世了，每次回想起他，我都悼念不已。請以此主題創作一首七言絕句。
每天晚上男友都跑出去外面玩，留我獨自一人在家，獨守空閨，十分難過。請以此主題創作一首七言律詩。
今天是學期最後一天，我開心地搭著車返鄉回家，或許是因為心情愉悅，沿途風景十分漂亮。請以此主題創作一首五言律詩。
可惜不是你，陪我到最後，曾一起走，卻走失那路口。請以此主題創作一首五言絕句。
今天是元宵節，很開心可以跟家人團聚一起吃湯圓，湯圓好好吃。請以此主題創作一首七言絕句。
今天是中秋節，但我一個人在外地工作，沒辦法回家團圓，非常想念我的家人。請以此主題創作一首七言律詩。
最近在準備研究所考試，希望可以考取榜首，壓力好大。請以此主題創作一首五言絕句。

壹、 基礎 RAG 和不使用 RAG 的比較實驗

表 4-2 基礎 RAG 和不使用 RAG 的比較實驗組合

A	使用基礎 RAG 進行生成
B	未使用 RAG 方法(僅單純使用 Gemini Pro)

一、 Answer Relevance

從表 4-4 可以看出，p-value = 0.016 < 0.05，表明在 Answer relevance 指標上，組別之間存在顯著差異；實驗 A 的平均為 0.721，實驗 B 則為 0.620，這說明是否使用 RAG 對 Answer relevance 指標具有顯著影響，當使用 RAG 時，能有效提升模型整體表現。

表 4-3 各組合之 Answer Relevance 指標實驗結果

	Answer Relevance	
	A	B
Median	0.778	0.594
Mean	0.721	0.620
Std. Deviation	0.150	0.199
Minimum	0.312	0.169
Maximum	0.898	0.906
25th percentile	0.615	0.502
50th percentile	0.778	0.594
75th percentile	0.854	0.754

表 4-4 Answer Relevance 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment number	0.188	1	0.188	6.065	0.016
Residuals	2.232	72	0.031		

Note. Type III Sum of Squares

二、 Execution Time

從表 4-6 可以看出，p-value < 0.001 < 0.05，表明在 Execution Time 指標上，組別之間存在顯著差異；實驗 A 的平均為 11.273。實驗 B 則為 3.240，說明是否使用 RAG 對 Execution Time 指標具有顯著影響，當使用 RAG 時，會使模型整體執行時間大幅增加。

表 4-5 各組合之 Execution Time 指標實驗結果

	Execution Time	
	A	B
Median	11.273	3.240
Mean	11.304	3.647
Std. Deviation	4.582	1.800
Minimum	3.898	1.953
Maximum	19.501	10.340
25th percentile	7.506	2.663
50th percentile	11.273	3.240
75th percentile	14.830	3.769

表 4-6 Execution Time 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment number	1084.441	1	1084.441	89.514	< .001
Residuals	872.261	72	12.116		

Note. Type III Sum of Squares

綜合上述兩指標的分析結果，可以了解到使用 RAG 相較於單純使用大型語言模型，能夠有效提升模型在唐詩生成任務上的表現，但也相對會增加回應生成所需執行時間。

貳、 Ablation Study 實驗

表 4-7 Ablation Study 實驗組合

	Sentiment Analysis	**HyDE**	**Cross-Encoders**	**Finetuned LLM**
A	0	1	1	1
B	1	0	1	1
C	1	1	0	1
D	1	1	1	0
E	1	1	1	1

一、 Answer Relevance

從表 4-9 可以看出，p-value < 0.001 < 0.05，表明在 Answer relevance 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用了 Tukey's HSD（Tukey's Honestly Significant Difference）進行事後檢定。根據表 4-10 的結果，實驗 D 和實驗 E 的 p-value = 0.027，顯示兩者之間存在顯著差異，又實驗 D 的平均為 0.657。實驗 E 則為 0.782，說明 Finetuned LLM 對 Answer relevance 指標具有顯著影響，當去除 Finetuned LLM 時，會導致模型整體表現下降。

表 4-8 各組合之 Answer Relevance 指標實驗結果

	Answer Relevance				
	A	B	C	D	E
Median	0.701	0.890	0.690	0.706	0.819
Mean	0.710	0.839	0.678	0.657	0.782
Std. Deviation	0.159	0.089	0.190	0.210	0.132
Minimum	0.415	0.538	0.239	0.244	0.377
Maximum	0.906	0.906	0.906	0.906	0.906
25th percentile	0.599	0.799	0.563	0.479	0.725
50th percentile	0.701	0.890	0.690	0.706	0.819
75th percentile	0.866	0.899	0.846	0.824	0.893

表 4-9 Answer Relevance 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment number	0.688	4	0.172	6.575	< .001
Residuals	3.795	145	0.026		

Note. Type III Sum of Squares

表 4-10 Answer Relevance 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
A	B	-0.129	0.042	-3.086	0.020
	C	0.032	0.042	0.768	0.939
	D	0.053	0.042	1.268	0.711
	E	-0.072	0.042	-1.724	0.423
B	C	0.161	0.042	3.853	0.002
	D	0.182	0.042	4.353	< .001
	E	0.057	0.042	1.362	0.653
C	D	0.021	0.042	0.500	0.987
	E	-0.104	0.042	-2.492	0.098
D	E	-0.125	0.042	-2.991	0.027

Note. P-value adjusted for comparing a family of 5

二、 Groundedness

從表 4-12 可以看出，p-value < 0.001 < 0.05，表明在 Groundedness 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用 Tukey's HSD 進行事後檢定。根據表 4-13 的結果，實驗 B 和實驗 E 的 p-value < 0.001，顯示兩者之間存在顯著差異，又實驗 B 的平均為 0.380。實驗 E 則為 0.680，說明 HyDE 對 Groundedness 指標具有顯著影響，當去除 HyDE 時，會導致模型整體表現下降。

表 4-11 各組合之 Groundedness 指標實驗結果

	Groundedness				
	A	B	C	D	E
Median	0.680	0.379	0.786	0.778	0.791
Mean	0.601	0.380	0.819	0.701	0.680
Std. Deviation	0.246	0.239	0.303	0.292	0.241
Minimum	0.061	0.010	0.308	0.019	0.022
Maximum	0.896	0.804	1.715	1.257	0.934
25th percentile	0.434	0.168	0.649	0.557	0.552
50th percentile	0.680	0.379	0.786	0.778	0.791
75th percentile	0.813	0.571	0.904	0.884	0.852

表 4-12 Groundedness 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	3.192	4	0.798	11.324	< .001
Residuals	10.219	145	0.070		

Note. Type III Sum of Squares

表 4-13 Groundedness 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
A	B	0.221	0.069	3.218	0.014
	C	-0.218	0.069	-3.182	0.015
	D	-0.101	0.069	-1.471	0.583
	E	-0.080	0.069	-1.164	0.772
B	C	-0.439	0.069	-6.400	< .001
	D	-0.321	0.069	-4.689	< .001
	E	-0.300	0.069	-4.382	< .001
C	D	0.117	0.069	1.711	0.430
	E	0.138	0.069	2.018	0.262
D	E	0.021	0.069	0.307	0.998

Note. P-value adjusted for comparing a family of 5

三、 Context Relevance

從表 4-15 可以看出 p-value = 0.004 < 0.05，表明在 Context relevance 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用了 Tukey's HSD 進行事後檢定。然而根據表 4-11 的結果，A、B、C、D 四個實驗和 E 的 p-value 皆大於 0.05，說明沒有單一方法對 Context Relevance 有顯著影響。

表 4-14 各組合之 Context Relevance 指標實驗結果

	Context Relevance				
	A	B	C	D	E
Median	0.419	0.499	0.585	0.470	0.613
Mean	0.430	0.609	0.518	0.418	0.544
Std. Deviation	0.159	0.163	0.280	0.227	0.237
Minimum	0.089	0.470	0.038	0.032	0.052
Maximum	0.696	0.835	0.901	0.831	0.895
25th percentile	0.333	0.470	0.235	0.204	0.351
50th percentile	0.419	0.499	0.585	0.470	0.613
75th percentile	0.567	0.798	0.716	0.588	0.716

表 4-15 Context Relevance 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	0.768	4	0.192	4.035	0.004
Residuals	6.901	145	0.048		

Note. Type III Sum of Squares

表 4-16 Context Relevance 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
A	B	-0.179	0.056	-3.175	0.016
	C	-0.088	0.056	-1.566	0.521
	D	0.012	0.056	0.208	1.000
	E	-0.114	0.056	-2.023	0.260
B	C	0.091	0.056	1.609	0.494
	D	0.191	0.056	3.382	0.008
	E	0.065	0.056	1.152	0.778
C	D	0.100	0.056	1.774	0.393
	E	-0.026	0.056	-0.456	0.991
D	E	-0.126	0.056	-2.230	0.175

Note. P-value adjusted for comparing a family of 5

四、 Execution Time

從圖 4-18 可以看出，p-value = 0.027 < 0.05，表明在 Execution Time 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用了 Tukey's HSD 進行事後檢定。然而根據圖 4-19 的結果，A、B、C、D 四個實驗和 E 的 p-value 皆大於 0.05，說明沒有單一方法對 Execution Time 有顯著影響。

表 4-17 各組合之 Execution Time 指標實驗結果

	Execution Time				
	A	B	C	D	E
Median	10.981	6.225	10.251	8.933	7.741
Mean	11.544	8.286	11.285	9.755	9.381
Std. Deviation	4.042	5.120	5.243	3.665	3.828
Minimum	6.849	2.857	6.482	4.928	5.689
Maximum	21.563	25.036	30.978	21.044	19.900
25th percentile	8.509	4.613	7.402	7.210	6.693
50th percentile	10.981	6.225	10.251	8.933	7.741
75th percentile	12.473	11.308	13.973	10.851	10.542

表 4-18 Execution Time 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	222.140	4	55.535	2.830	0.027
Residuals	2845.567	145	19.625		

Note. Type III Sum of Squares

表 4-19 Execution Time 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
A	B	3.258	1.144	2.849	0.040
	C	0.259	1.144	0.227	0.999
	D	1.789	1.144	1.564	0.523
	E	2.164	1.144	1.892	0.327
B	C	-2.999	1.144	-2.622	0.072
	D	-1.469	1.144	-1.284	0.701
	E	-1.095	1.144	-0.957	0.874
C	D	1.530	1.144	1.338	0.668
	E	1.904	1.144	1.665	0.459
D	E	0.374	1.144	0.327	0.998

Note. P-value adjusted for comparing a family of 5

綜合上述四個指標，可以了解 HyDE、Finetuned LLM 對 RAG 結果的表現有顯著影響，當加入此二模塊時，會提升模型表現結果，Sentiment Analysis 以及 Cross-Encoder 則無顯著影響。

參、 全因子實驗

透過前一節的 Ablation Study 實驗，我們發現 HyDE 和 Fine-tuned LLM 對模型表現具有顯著影響。因此，本研究進一步進行全因子實驗，以探討 HyDE 與 Fine-tuned LLM 的所有可能組合對模型表現的影響。

表 4-20 全因子實驗組合

Experiment_ID	HyDE	Finetuned LLM
1	0	0
2	1	0
3	0	1
4	1	1

一、 Answer Relevance

從表 4-22 可以看出，在 ANOVA 檢驗中，p-value = 0.064 > 0.05，表明在 Answer Relevance 指標上，不同組別之間不存在顯著差異。

表 4-21 各組合之 Answer Relevance 指標實驗結果

	Answer Relevance			
	1	2	3	4
Median	0.813	0.695	0.845	0.818
Mean	0.780	0.667	0.787	0.737
Std. Deviation	0.143	0.229	0.149	0.195
Minimum	0.223	0.049	0.350	0.134
Maximum	0.904	0.906	0.906	0.906
25th percentile	0.706	0.581	0.699	0.621
50th percentile	0.813	0.695	0.845	0.818
75th percentile	0.895	0.870	0.896	0.878

表 4-22 Answer Relevance 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	0.242	3	0.081	2.483	0.064
Residuals	3.764	116	0.032		

Note. Type III Sum of Squares

二、 Groundedness

從表 4-24 可以看出，ANOVA 檢驗中 p-value < 0.001 < 0.05，表明在 Groundedness 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用了 Tukey's HSD 進行事後檢定。根據表 4-25 的結果，實驗 2、實驗 3 和實驗 4 分別與實驗 1 的 p-value 均小於 0.001，顯著小於 0.05，顯示實驗 1 與其他三者之間存在顯著差異。進一步根據四個實驗的平均值分析：實驗 1 平均為 0.241，實驗 2 為 0.640，實驗 3 為 0.525，實驗 4 為 0.609。這說明在 Groundedness 指標上，未使用 Advanced RAG 方法的模型（實驗 1）表現顯著劣於其他使用 Advanced RAG 方法的模型（實驗 2、實驗 3 和實驗 4）。

表 4-23 各組合之 Groundedness 指標實驗結果

	Groundedness			
	1	2	3	4
Median	0.223	0.718	0.497	0.658
Mean	0.241	0.640	0.525	0.609
Std. Deviation	0.171	0.221	0.198	0.241
Minimum	0.010	0.203	0.076	0.163
Maximum	0.698	0.924	0.911	0.933
25th percentile	0.119	0.440	0.411	0.418
50th percentile	0.223	0.718	0.497	0.658
75th percentile	0.361	0.807	0.616	0.822

表 4-24 Groundedness 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	2.964	3	0.988	22.527	< .001
Residuals	5.088	116	0.044		

Note. Type III Sum of Squares

表 4-25 Groundedness 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
1	2	-0.399	0.054	-7.370	< .001
	3	-0.283	0.054	-5.241	< .001
	4	-0.367	0.054	-6.790	< .001
2	3	0.115	0.054	2.130	0.150
	4	0.031	0.054	0.581	0.938
3	4	-0.084	0.054	-1.549	0.412

Note. P-value adjusted for comparing a family of 4

三、 Context Relevance

從表 4-27 可以看出，在 ANOVA 檢驗中，p-value = 0.099 > 0.05，表明在 Context relevance 指標上，不同組別之間不存在顯著差異。

表 4-26 各組合之 Context Relevance 指標實驗結果

	Context Relevance			
	1	2	3	4
Median	0.721	0.679	0.742	0.695
Mean	0.713	0.648	0.727	0.675
Std. Deviation	0.138	0.149	0.134	0.112
Minimum	0.417	0.277	0.385	0.425
Maximum	0.883	0.859	0.883	0.894
25th percentile	0.659	0.537	0.651	0.611
50th percentile	0.721	0.679	0.742	0.695
75th percentile	0.854	0.759	0.842	0.760

表 4-27 Context Relevance 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	0.115	3	0.038	2.140	0.099
Residuals	2.068	115	0.018		

Note. Type III Sum of Squares

四、 Execution time

從表 4-29 可以看出，ANOVA 檢驗中 p-value < 0.001 < 0.05，表明在 Execution Time 指標上，不同組別（由不同方法組合形成）之間存在顯著差異。隨後，研究採用 Tukey's HSD（Tukey’s Honestly Significant Difference）進行事

後檢定。根據表 4-30 的結果，實驗 1 與實驗 2、實驗 1 與實驗 4、實驗 2 與實驗 3 以及實驗 3 與實驗 4 之間均存在顯著差異。根據四個實驗的平均值分析：實驗 1 為 6.253，實驗 2 為 11.428，實驗 3 為 6.660，實驗 4 為 10.516。這表明，使用 HyDE 的實驗組合（實驗 2 和實驗 4）所需的執行時間顯著高於未使用 HyDE 的實驗組合（實驗 1 和實驗 3）。

表 4-28 各組合之 Execution time 指標實驗結果

	Execution time			
	1	2	3	4
Median	4.511	10.399	5.191	7.24
Mean	6.253	11.428	6.660	10.516
Std. Deviation	5.446	5.218	5.012	5.902
Minimum	2.460	5.180	2.540	4.890
Maximum	25.953	23.877	27.922	26.412
25th percentile	3.514	7.410	3.768	6.071
50th percentile	4.511	10.399	5.191	7.240
75th percentile	5.251	13.662	7.275	14.932

表 4-29 Execution time 指標之 ANOVA 檢定

Cases	Sum of Squares	df	Mean Square	F	p
experiment_number	626.725	3	208.908	7.152	< .001
Residuals	3388.450	116	29.211		

Note. Type III Sum of Squares

表 4-30 Execution time 指標之 Post Hoc Comparisons

		Mean Difference	SE	t	p_{tukey}
1	2	-5.175	1.395	-3.709	0.002
	3	-0.408	1.395	-0.292	0.991
	4	-4.264	1.395	-3.055	0.015
2	3	4.768	1.395	3.417	0.005
	4	0.912	1.395	0.653	0.914
3	4	-3.856	1.395	-2.763	0.033

Note. P-value adjusted for comparing a family of 4

綜合上述四個指標可以看出，無論是僅使用 HyDE、僅使用 Fine-tuned LLM，或是同時結合兩者的 Advanced RAG 方法組合，相較於未使用 Advanced RAG 的模型，都展現出顯著更佳的性能，並在唐詩生成的表現上有明顯優勢。另外，若模型中包含使用 HyDE 的方法，則會顯著增加模型的執行時間。

第三節 國文領域專家問卷分析

總結專家問卷結果，分析生成詩作在國文領域專家評分中的表現差異，此問卷中分為兩個方面，一為實際存在之唐詩，另一為大型語言模型生成之詩句。而在大型語言模型生成，又分為由本研究架構出之 RAG 模型 self-design RAG、Gemini Pro、GPT 4o 三部分，問卷中大型語言模型生成之詩句是以相同的敘述使之生成，減少實驗的變數。在問卷中，以單盲實驗的方式使專家填答，避免受到主觀意識影響。對實際存在之唐詩、self-design RAG、Gemini Pro 、Gpt4o 各 34 則詩詞總體評分回應做平均值分析。

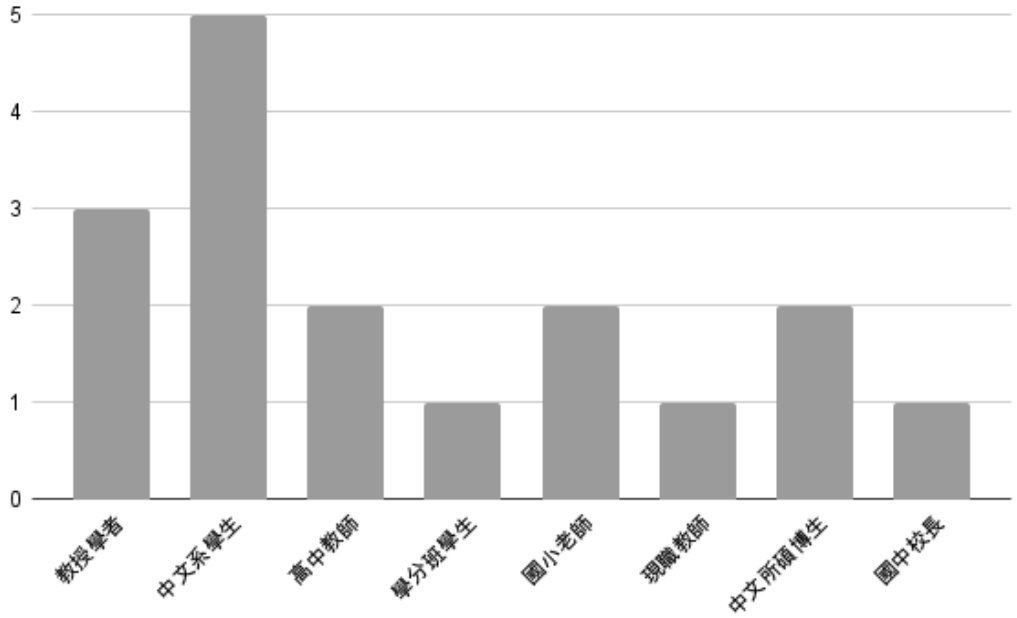

圖 **4-2** 填答人員背景分布

表 **4-31** 實際唐詩與大型語言模型生成詩句之平均值比較

Sample	**N**	**Mean**	**StDev**	**SE Mean**
Tang poem	34	3.471	0.964	0.17
LLM generate	102	3.484	0.953	0.094

Note. Tang Poem 指實際存在之唐詩

表 **4-32** 實際唐詩與大型語言模型生成詩句之 **T** 檢定

Null hypothesis	H_0: $\mu_1 - \mu_2 = 0$
Alternative hypothesis	H_1: $\mu_1 - \mu_2 \neq 0$

T-Value	**DF**	**P-Value**
-0.07	56	0.946

表 **4-33** self-design RAG 與 **Gemini Pro** 之平均值比較

Sample	**N**	**Mean**	**StDev**	**SE Mean**
self-design RAG	34	3.564	0.958	0.16
Gemini	34	3.510	0.918	0.16

表 **4-34** self-design RAG 與 **Gemini Pro** 之 **T** 檢定

Null hypothesis	H_0: $\mu_1 - \mu_2 = 0$
Alternative hypothesis	H_1: $\mu_1 - \mu_2 \neq 0$

T-Value	**DF**	**P-Value**
-0.24	65	0.813

表 **4-35** self-design RAG 與 **Gpt4o** 之平均值比較

Sample	**N**	**Mean**	**StDev**	**SE Mean**
self-design RAG	34	3.564	0.958	0.16
Gpt4o	34	3.377	0.977	0.17

表 **4-36** self-design RAG 與 **Gpt4o** 之 **T** 檢定

Null hypothesis	H_0: $\mu_1 - \mu_2 = 0$
Alternative hypothesis	H_1: $\mu_1 - \mu_2 \neq 0$

T-Value	**DF**	**P-Value**
-0.79	65	0.430

在從表 4-32、4-34、4-36 的檢定中，可以看到其 p-value 皆大於 0.05，說明實際唐詩與各模型生成詩句之總體評分並未有顯著差距，可以推測專家無法有效分辨實際唐詩與大型語言模型生成之詩句。

然而在專家所給出之回饋中仍有提出少許詩句在押韻當中有所錯誤，有一專家指出表單中以「ㄋ」結尾的詩，皆為古韻中的「出韻」，並不符合唐詩「平水韻」的用韻規則；另一專家指出少許詩句中有些許單詞不符合古典詩詞常用之用法，應須多加注意。

第四節 小結

綜合上述的實驗以及問卷分析，研究結果顯示透過引入 RAG 方法能夠顯著提升大型語言模型在唐詩生成任務上的表現，但同時也增加回應生成所需的時間。在進一步採用包含 HyDE 及 Finetuned LLM 的 Advanced RAG 方法後，模型表現有更明顯的改善，然而 HyDE 的使用會顯著拉長模型執行時間。相對地，Sentiment Analysis 與 Cross-Encoder 對模型表現的提升並無顯著影響。

雖然統計檢定顯示實際唐詩與模型生成詩句間在專家評分上無顯著差異，顯示專家在整體上難以區分，但部分專家仍對生成結果的細微處提出了質疑，包括古韻「出韻」的狀況以及特定詞彙用法不符合傳統詩詞習慣等問題。綜上可知，模型在唐詩生成有良好表現的同時，仍有必要針對古典用韻規範及詞彙使用加以改進。

第五章 結論與未來展望

第一節 結論

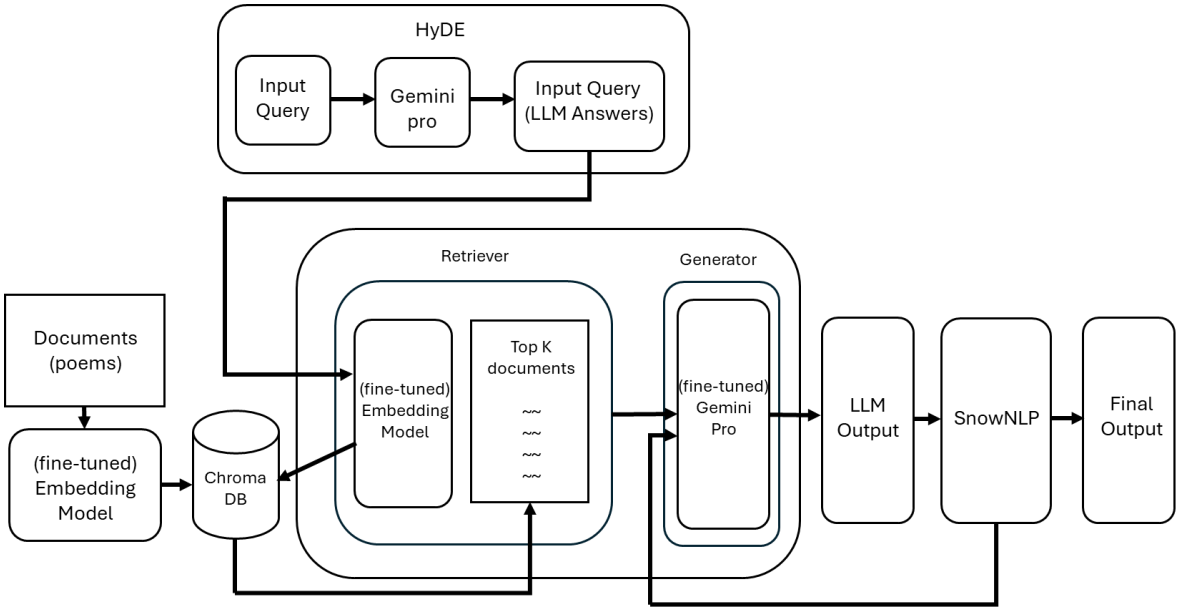

圖 5-1 系統最終架構圖

本研究以 Advanced RAG 技術輔助大型語言模型（LLM），針對輸入內容生成詩句，並通過實驗進行了分析。根據實驗結果，我們可以得出以下主要結論：

提升詩句生成的表現：在唐詩生成的任務中，相較於僅依靠大型語言模型，採用 RAG（Retrieval-Augmented Generation）能夠取得更佳的表現。

方法的適用性與潛力：本研究證實 Advanced RAG 中的 HyDE 以及 Finetuned LLM 方法在提升詩句生成表現中的有效性，特別是在需要高水準語言生成的文本創作任務上。此方法的靈活性和適用性表明，未來可拓展至其他文學體裁或不同語言生成任務中。並在研究最後，實作出最終系統架構，如圖 5-1。

詩的文學品質：在問卷調查中，多數填寫者無法分辨由本研究之 RAG 模型所

生成的詩句與現存詩作之間的差異，顯示此技術可使生成的詩作在文學風格和質感上與真實作品相當接近。

第二節 研究貢獻

本研究的貢獻在於探索 RAG 技術於詩句生成的潛在應用，並提供一套全面的評估框架，結合餘弦相似度量化分數與專家問卷評分，全面評估生成詩的相關性和文學品質。研究不僅為語言模型在文學創作上的應用提供新視角，還拓展了詩句生成技術的發展方向。

第三節 未來展望

基於本研究的發現，未來研究可進一步探討以下幾個方向：

增加文本 RAG 準確性：利用 Graph RAG 對於詩的分類和查詢進行更一步的提升，以增加 RAG 結果和使用者輸入內容的貼合。

提升人機協作的創作能力：未來可探索將 RAG 應用於人機協作寫作中，讓模型生成詩句後由人類進行後續修改，結合人類創意和模型自動生成的優勢，提升創作效率與表達效果。

深化文學性評估方法：本研究中，評估模型生成詩的文學性仍具有挑戰性，未來可以進一步細化問卷評估指標，或探索更多能量化文學品質的評估方法，以使生成詩句的審美價值能更為客觀且精確地呈現。

總結而言，本研究證實 RAG 在詩句生成應用上的可行性，為語言模型在文學創作領域的未來應用提供新的方向。隨著生成模型技術的進步，我們能期待模型在

文本生成品質與創意表達方面的持續提升。

第三節 系統演示

圖 5-2 系統使用者介面

一、 範例一

使用者輸入：今天是中秋節，我一個人心情很不好，可以幫我生成一首七言絕句撫慰我的心情嗎？

系統回覆：

月上柳梢人獨愁，

思鄉念親淚難收。

遙望千里寄相思，

但願明月寄我憂。

二、 範例二

使用者輸入：今天是除夕，我為了考試沒辦法回家團圓，可以寫一首五言絕句安慰我嗎？

系統回覆：

除夕不能團，

心緒難平復，

他年定衣錦，

今朝且讀書。

三、 範例三

使用者輸入：今天是端午節，我吃到了美味的粽子，我覺得很開心，幫我生成一首符合我心情的七言律詩

系統回覆：

糉香盈室喜洋洋，佳節端午樂滿堂。

糯米綿軟心歡暢，豆餡香甜福氣長。

艾葉飄香驅邪祟，龍舟競渡慶安康。

糉子情誼綿綿長，端午安康樂無疆。

四、 範例四

使用者輸入：今天是清明節，我思念我過世的家人，可以生成一首五言律詩安慰我嗎？

系統回覆：

清明寄哀思，遙祭故人魂。

音容常在夢，淚灑故鄉墳。

故土情難斷，遙寄片紙文。

但願彼岸安，春風化細塵。

第六章 參考文獻

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2021). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Facebook AI Research; University College London; New York University

Shahul Es, J., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated Evaluation of Retrieval Augmented Generation. Exploding Gradients; CardiffNLP, Cardiff University

Luyu Gao ,Xueguang Ma, Jimmy Lin,Jamie Callan(2022)

Precise Zero-Shot Dense Retrieval without Relevance Labels

Zhao, Zijie and Roy E. Welsch. “Aligning LLMs with Human Instructions and Stock Market Feedback in Financial Sentiment Analysis.” (2024).

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP). Association for Computational Linguistics.

Pickett, M., Hartman, J., Bhowmick, A. K., Alam, R.-u., & Vempaty, A. (2024). Better RAG using Relevant Information Gain. Emergence AI.

Nussbaum, Z., Morris, J. X., Duderstadt, B., & Mulyar, A. (2024). Nomic Embed: Training a Reproducible Long Context Text Embedder

Narayanan, V. Hari, Ishani Arora and Arjun Bhatia. “Fast and Accurate Sentiment Classification Using an Enhanced Naive Bayes Model.” ArXiv abs/1305.6143

(2013): n. pag.

Rodrigo Nogueira and Kyunghyun Cho. 2020. Passage re-ranking with bert. Preprint, arXiv:1901.04085.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, arXiv:1810.04805

Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Carbonell, Ruslan Salakhutdinov, Quoc V. Le, “XLNet: Generalized Autoregressive Pretraining for Language Understanding”, arXiv:1906.08237

OpenAI. (2019). Better Language Models and Their Implications. Retrieved from https://openai.com/blog/better-language-models